МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №1
по дисциплине «Интеллектуальные методы анализа данных»
Тема: Первичный анализ и предобработка природного временного ряда.

Студент гр. 3384 _____ Рудаков А.Л.

Преподаватель _____ Мандрикова Б.С.

Санкт-Петербург
2026

Цель работы.

Повышение качества природных данных на примере наблюдений нейтронных мониторов.

Задание.

Вариант 20(3). Тикси (TXBY) 1-9 августа 2015

1. Скачать данные из источника за периоды и станции, указанные по вариантам в таблице. Использовать данные с одноминутным временным разрешением.

2. Выполнить обнаружение пропусков и выбросов в анализируемом временном ряде, посчитать их количество и долю от всех обрабатываемых данных.

3. Вычислить медианное значение по данным без пропусков и выбросов.

4. Заменить пропуски и выбросы медианными значениями.

5. Изобразить графики исходного и полученного временных рядов.

6. Сделать соответствующие выводы, оформить отчет по работе.

Выполнение работы.

Работа выполнялась в Jupiter Notebook, Python.

Для начала были найдены пропуски данных во временном ряду, путем сравнения полученных данных с эталонным временным рядом с шагом в 1 минуту. Суммарно найдено 59 пропусков. Доля от всех 0.005.

Далее было найдено среднее значение (109.730) и стандартное отклонение (79.651). После чего было применено правило 3-сигма (среднее +- 3 сигма), благодаря которому было найдено 198 выбросов. Доля от всех 0.015. Далее среди данных, не являющихся выбросами и пропусками была найдена медиана (97.867) и все выбросы и пропуски заполнены данным значением.

Однако на мой взгляд для данных с такими выбросами подходит не идеально, так как из-за выбросов СКО становится большим и правило отсекает

лишь самые крупные выбросы, при этом все равно остаются значения сильно выше медианных (в 3 раза). Поэтому решено добавить более жесткое правило для выбросов: IQR.

Для правила IQR был найден 25-ый перцентиль (96.4), 75-ый перцентиль (99.6), значение IQR = 3.2, после чего, по правилу IQR ([Q1-IQR, Q3+IQR])было найдено 2102 выброса. Доля от всех 0.162. После чего найдена медиана по чистым значениям (97.733) и все выбросы и пропуски заполнены данным значением.

Графики начального временного ряда, временного ряда, после применения правила 3-сигма и временного ряда, после применения правила IQR представлены на рис.1.

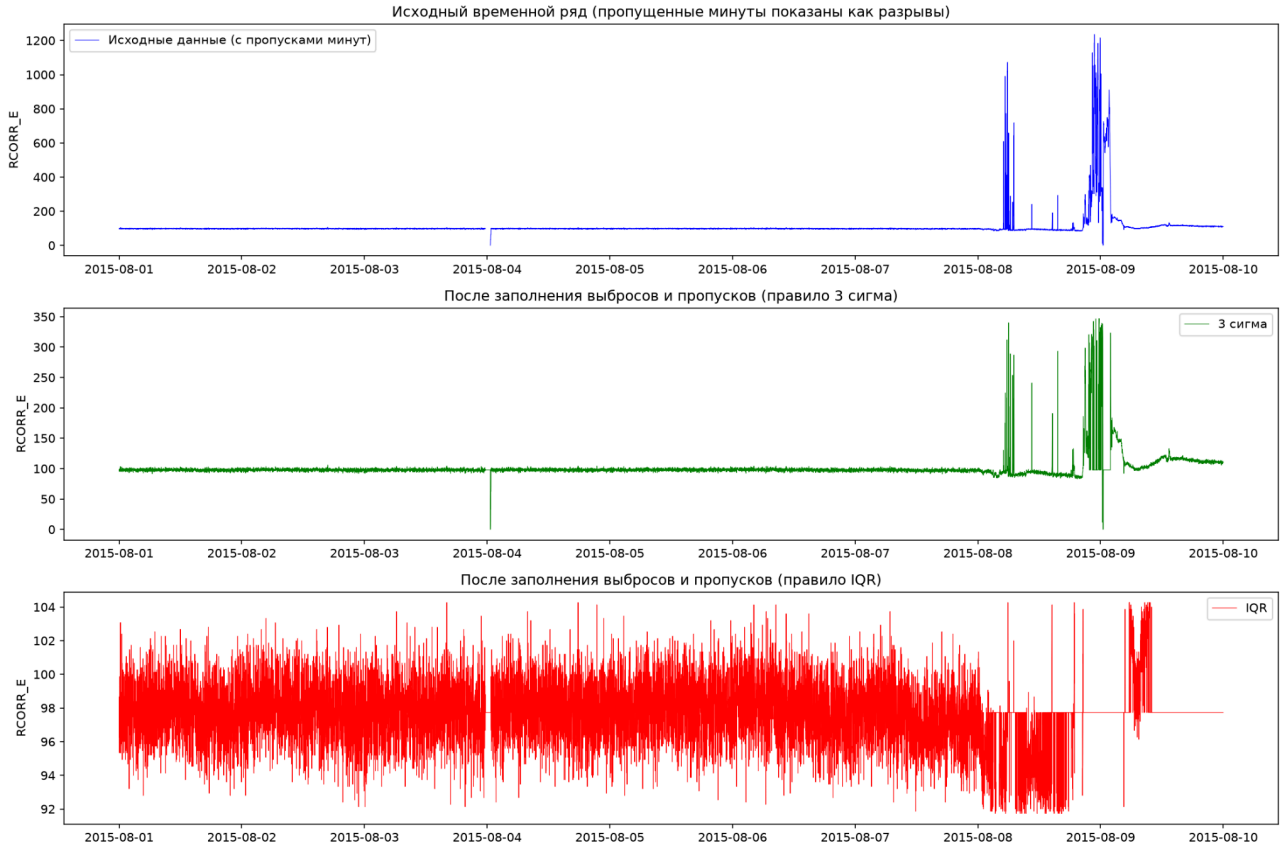


Рисунок 1 - графики полученных временных рядов

Выводы.

В ходе лабораторной работы была выполнена обработка данных нейтронного монитора станции Тикси за период с 1 по 9 августа 2015 года. Найдено 59 пропусков в данных. Данные очищены двумя методами: 3-сигма и

IQR. В первом случае доля выбросов составила 0.015, во втором случае 0.162. Приведены графики полученных временных рядов.

ПРИЛОЖЕНИЕ А
ИСХОДНЫЙ КОД

Файл mpi_lb2.cpp:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
df = pd.read_csv(
    'data.txt',
    sep=';',
    skiprows=1,
    names=['start_date_time', 'RCORR_E'],
    parse_dates=['start_date_time']
)

print("Размер данных:", df.shape)
print("Количество NULL в RCORR_E:", df['RCORR_E'].isna().sum())
print(df.head())

full_range = pd.date_range(
    start=df['start_date_time'].min(),
    end=df['start_date_time'].max(),
    freq='1min'
)

existing = set(df['start_date_time'])

missing_minutes = [t for t in full_range if t not in existing]

print(f"Всего минут в диапазоне: {len(full_range)}")
print(f"Пропущено минут: {len(missing_minutes)}")
print(f"Доля пропущенных минут: {len(missing_minutes)/len(full_range):.3f}")

if missing_minutes:
    df_missing = pd.DataFrame({
        'start_date_time': missing_minutes,
        'RCORR_E': np.nan
    })
    df = pd.concat([df, df_missing], ignore_index=True)
    df = df.sort_values('start_date_time').reset_index(drop=True)

df_sigma = df.copy()
```

```
missing_mask = df_sigma['RCORR_E'].isna()

valid_data = df_sigma.loc[~missing_mask, 'RCORR_E']
mean_val = valid_data.mean()
std_val = valid_data.std()

outlier_mask = (df_sigma['RCORR_E'] < mean_val - 3 * std_val) | \
               (df_sigma['RCORR_E'] > mean_val + 3 * std_val)
outlier_mask = outlier_mask & (~missing_mask)

print(f"Среднее: {mean_val:.3f}, стандартное отклонение: {std_val:.3f}")
print(f"Количество выбросов по правилу 3 сигма: {outlier_mask.sum()}")
print(f"Доля выбросов: {outlier_mask.sum()/len(full_range):.3f}")

clean_data_sigma = df_sigma.loc[~missing_mask & ~outlier_mask, 'RCORR_E']
median_sigma = clean_data_sigma.median()
print(f"Медиана: {median_sigma:.3f}")

df_sigma.loc[missing_mask | outlier_mask, 'RCORR_E'] = median_sigma

df_iqr = df.copy()

missing_mask_iqr = df_iqr['RCORR_E'].isna()

valid_data_iqr = df_iqr.loc[~missing_mask_iqr, 'RCORR_E']
Q1 = valid_data_iqr.quantile(0.25)
Q3 = valid_data_iqr.quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

outlier_mask_iqr = (df_iqr['RCORR_E'] < lower_bound) | (df_iqr['RCORR_E'] > upper_bound)
outlier_mask_iqr = outlier_mask_iqr & (~missing_mask_iqr)

print(f"Q1 = {Q1:.3f}, Q3 = {Q3:.3f}, IQR = {IQR:.3f}")
print(f"Границы: [{lower_bound:.3f}, {upper_bound:.3f}]")
print(f"Количество выбросов по правилу IQR: {outlier_mask_iqr.sum()}")
print(f"Доля выбросов: {outlier_mask_iqr.sum()/len(full_range):.3f}")

clean_data_iqr = df_iqr.loc[~missing_mask_iqr & ~outlier_mask_iqr, 'RCORR_E']
```

```
median_iqr = clean_data_iqr.median()
print(f"Медиана: {median_iqr:.3f}")

df_iqr.loc[missing_mask_iqr | outlier_mask_iqr, 'RCORR_E'] = median_iqr

fig, axes = plt.subplots(3, 1, figsize=(15, 10))

axes[0].plot(df['start_date_time'], df['RCORR_E'],
        color='blue', linewidth=0.5,
        label='Исходные данные (с пропусками минут)')
axes[0].set_title('Исходный временной ряд (пропущенные минуты показаны как разрывы)')
axes[0].set_ylabel('RCORR_E')
axes[0].legend()

axes[1].plot(df_sigma['start_date_time'], df_sigma['RCORR_E'],
        color='green', linewidth=0.5, label='3 сигма')
axes[1].set_title('После заполнения выбросов и пропусков (правило 3 сигма)')
axes[1].set_ylabel('RCORR_E')
axes[1].legend()

axes[2].plot(df_iqr['start_date_time'], df_iqr['RCORR_E'],
        color='red', linewidth=0.5, label='IQR')
axes[2].set_title('После заполнения выбросов и пропусков (правило IQR)')
axes[2].set_ylabel('RCORR_E')
axes[2].legend()

fig.tight_layout()

#fig.savefig('timeseries_plots.png', dpi=150, bbox_inches='tight')

plt.show()
```